TP: Estadística descriptiva agrícola

Dataset: datos_agricultura.csv (30 lotes: soja, maíz y trigo)

Beverly González C.

24/10/2026

Parte 1: Exploración de los datos

1. Cargar los datos

```
datos <- read.csv("data/datos_agricultura.csv", fileEncoding = "UTF-8-BOM")
```

2. Primeros 6 registros

```
head(datos, 6)
```

```
##   lote cultivo superficie_ha rendimiento_t_ha lluvia_mm fertilizante_kg_ha tipo_suelo
## 1    1    Soja            45              2.8       620                 90     Franco
## 2    2    Soja            62              3.1       680                100     Franco
## 3    3    Soja            38              2.6       590                 85  Arcilloso
## 4    4    Soja            75              3.4       710                110     Franco
## 5    5    Soja            54              3.0       650                 95    Arenoso
## 6    6    Maiz            80              7.2       720                140     Franco
##   riego
## 1    No
## 2    Si
## 3    No
## 4    Si
## 5    No
## 6    Si
```

3. Lotes que contiene la base

```
n_lotes <- nrow(datos)
cat("La base contiene", n_lotes, "lotes.\n")
```

```
## La base contiene 30 lotes.
```

4. Variables

```
n_vars <- ncol(datos)
cat("La base contiene", n_vars, "variables:",
    paste(names(datos), collapse = ", "), "\n")
```

```
## La base contiene 8 variables: lote, cultivo, superficie_ha, rendimiento_t_ha, lluvia_mm, ferti
```

5. Categóricas y numéricas

```
str(datos)
```

```
## 'data.frame':    30 obs. of  8 variables:
##  $ lote              : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ cultivo           : chr  "Soja" "Soja" "Soja" "Soja" ...
##  $ superficie_ha     : int  45 62 38 75 54 80 65 92 48 70 ...
##  $ rendimiento_t_ha  : num  2.8 3.1 2.6 3.4 3 7.2 6.8 8.1 6.5 7.5 ...
##  $ lluvia_mm         : int  620 680 590 710 650 720 750 810 690 780 ...
##  $ fertilizante_kg_ha: int  90 100 85 110 95 140 130 160 120 150 ...
##  $ tipo_suelo        : chr  "Franco" "Franco" "Arcilloso" "Franco" ...
##  $ riego             : chr  "No" "Si" "No" "Si" ...
```

```
tipos <- data.frame(variable = names(datos),
                    clase_R = sapply(datos, class),
                    tipo = c("identificador", "categórica", "numérica", "numérica",
                             "numérica", "numérica", "categórica", "categórica"),
                    row.names = NULL
                    )
tipos
```

```
##             variable   clase_R          tipo
## 1               lote   integer identificador
## 2            cultivo character    categórica
## 3      superficie_ha   integer      numérica
## 4   rendimiento_t_ha   numeric      numérica
## 5          lluvia_mm   integer      numérica
## 6 fertilizante_kg_ha   integer      numérica
## 7         tipo_suelo character    categórica
## 8              riego character    categórica
```

6. Resumen estadístico de las variables numéricas

```
vars_num <- c("superficie_ha", "rendimiento_t_ha", "lluvia_mm", "fertilizante_kg_ha")
summary(datos[, vars_num])
```

```
##  superficie_ha   rendimiento_t_ha   lluvia_mm     fertilizante_kg_ha
##  Min.   :38.00   Min.   :2.600    Min.   :590.0   Min.   : 75.0
##  1st Qu.:52.50   1st Qu.:3.125    1st Qu.:640.0   1st Qu.: 90.0
##  Median :62.50   Median :3.950    Median :675.0   Median :100.0
##  Mean   :63.27   Mean   :4.737    Mean   :685.7   Mean   :108.8
##  3rd Qu.:73.75   3rd Qu.:6.875    3rd Qu.:727.5   3rd Qu.:128.8
##  Max.   :92.00   Max.   :8.100    Max.   :810.0   Max.   :160.0
```

Parte 2: Medidas de tendencia central

Variable analizada: `rendimiento_t_ha`.

```r
r <- datos$rendimiento_t_ha
```

7. Media

```r
media <- mean(r)
cat("La media del rendimiento es", round(media, 2), "t/ha\n")
```

```
## La media del rendimiento es 4.74 t/ha
```

8. Mediana

```r
mediana <- median(r)
cat("La mediana del rendimiento es", mediana, "t/ha\n")
```

```
## La mediana del rendimiento es 3.95 t/ha
```

9. Moda

```r
# R no trae una función de moda, asi que debo verificar en la tabla de frecuencias
frecuencias <- table(r)
moda <- names(frecuencias)[frecuencias == max(frecuencias)]
cat("Moda(s):", moda, "- cada una aparece", max(frecuencias), "veces\n")
```

```
## Moda(s): 3 3.1 4.1 - cada una aparece 2 veces
```

Hay tres modas (3,0; 3,1 y 4,1), con solo 2 lotes cada una: aporta poco. Además, todas están en el grupo de rendimientos bajos, así que la tabla de frecuencias no detecta el segundo grupo.

10. Comparar media y mediana

```r
sort(r)
```

```
##  [1] 2.6 2.7 2.8 2.9 3.0 3.0 3.1 3.1 3.2 3.3 3.4 3.6 3.7 3.8 3.9 4.0 4.1 4.1 4.2 4.3 6.5
## [22] 6.8 6.9 7.1 7.2 7.4 7.5 7.8 8.0 8.1
```

```r
tapply(r, datos$cultivo, median)
```

```
##  Maiz  Soja Trigo
##   7.3   3.0   4.0
```

La media (4,74 t/ha) es mayor que la mediana (3,95 t/ha), y en `sort(r)` se ve que los lotes se juntan en dos grupos: 20 lotes entre 2,6 y 4,3 t/ha y 10 lotes entre 6,5 y 8,1 t/ha, sin ningún lote entre 4,3 y 6,5. La media cae justo en ese hueco, así que ningún lote rinde cerca del promedio. La mediana refleja mejor al grupo mayoritario, pero tampoco describe a los lotes de maíz. Una sola medida no alcanza. No puedo afirmar todavía que la diferencia entre grupos se deba solo al cultivo.

Parte 3: Dispersión y posición

Variable analizada: `rendimiento_t_ha`.

```r
r <- datos$rendimiento_t_ha
```

11. Mínimo y máximo

```r
minimo <- min(r)
maximo <- max(r)
cat("Mínimo:", minimo, "t/ha - Máximo:", maximo, "t/ha\n")
```

```
## Mínimo: 2.6 t/ha - Máximo: 8.1 t/ha
```

12. Rango

```r
rango <- maximo - minimo
cat("Rango:", rango, "t/ha\n")
```

```
## Rango: 5.5 t/ha
```

13. Q1, Q2 y Q3

```r
cuartiles <- quantile(r, probs = c(0.25, 0.50, 0.75))
cuartiles
```

```
##   25%   50%   75%
## 3.125 3.950 6.875
```

14. Rango intercuartílico (IQR)

```r
iqr <- IQR(r)   # Q3 - Q1
cat("IQR:", iqr, "t/ha\n")
```

```
## IQR: 3.75 t/ha
```

15. ¿Entre qué valores está el 50 % central de los rendimientos?

```r
cat("El 50 % central va de", cuartiles[1], "a", cuartiles[3], "t/ha\n")
```

```
## El 50 % central va de 3.125 a 6.875 t/ha
```

El 50 % central de los rendimientos va de 3,125 a 6,875 t/ha (IQR = 3,75 t/ha), un intervalo muy amplio. Ese intervalo mezcla cultivos con niveles de rendimiento distintos y abarca el hueco donde no hay ningún lote. Para un productor, un rendimiento típico general no sirve: la expectativa depende del cultivo.

Parte 4: Gráficos

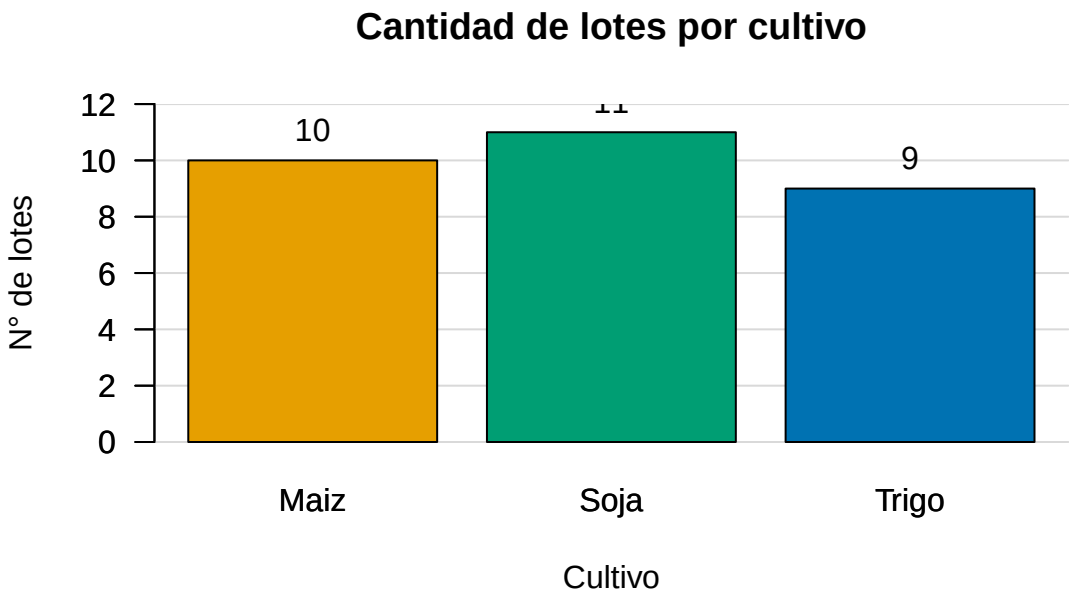
Un color fijo por cultivo, el mismo en todos los gráficos.

```r
colores <- c(Maiz = "#E69F00", Soja = "#009E73", Trigo = "#0072B2")
```

Barras: lotes por cultivo

```r
par(las = 1)   # los números del eje quedan en horizontal
conteo <- table(datos$cultivo)

barplot(conteo, ylim = c(0, 12), col = NA, border = NA,
        main = "Cantidad de lotes por cultivo",
        xlab = "Cultivo", ylab = "N° de lotes")
grid(nx = NA, ny = NULL, col = "gray85", lty = 1)
bp <- barplot(conteo, col = colores[names(conteo)], add = TRUE)
text(bp, as.vector(conteo), labels = as.vector(conteo), pos = 3)
```

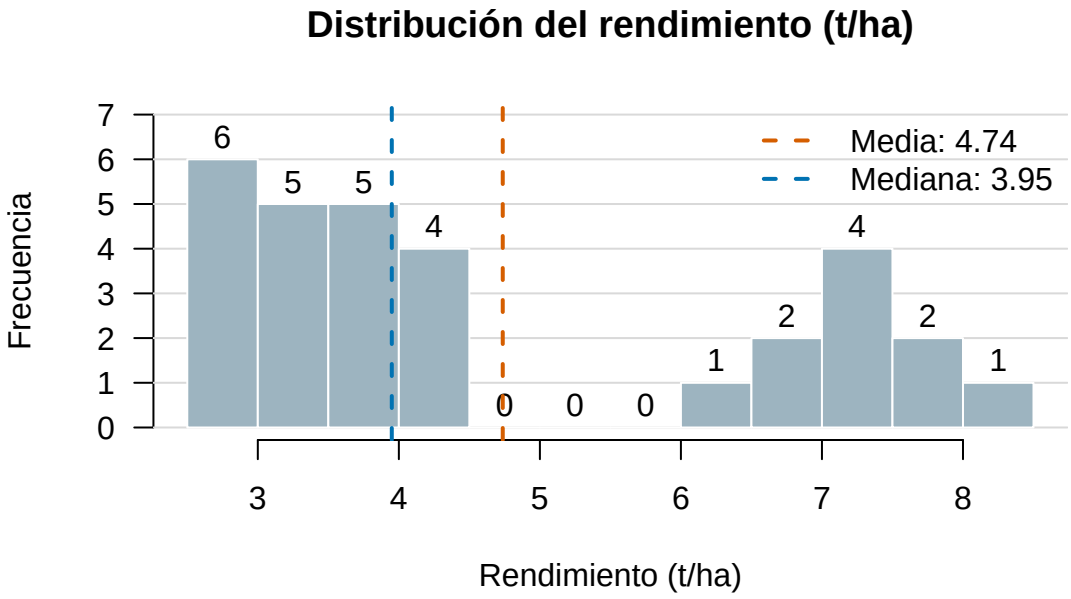


Soja 11 lotes, maíz 10 y trigo 9. La base se ve equilibrada entre cultivos, por lo que ninguno pesa de más en las medidas generales.

Histograma: distribución del rendimiento

```
par(las = 1)
cortes <- seq(2.5, 8.5, by = 0.5)

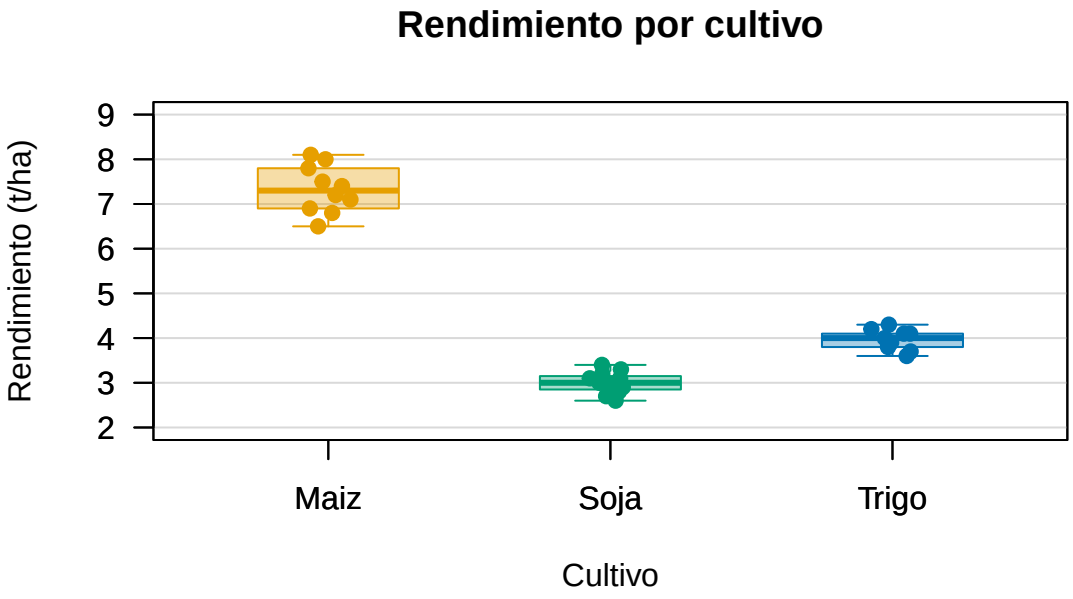
hist(r, breaks = cortes, ylim = c(0, 7), col = NA, border = NA,
     main = "Distribución del rendimiento (t/ha)",
     xlab = "Rendimiento (t/ha)", ylab = "Frecuencia")
grid(nx = NA, ny = NULL, col = "gray85", lty = 1)
hist(r, breaks = cortes, col = "#9DB4C0", border = "white",
     labels = TRUE, add = TRUE)
abline(v = media,   lty = 2, lwd = 2, col = "#D55E00")
abline(v = mediana, lty = 2, lwd = 2, col = "#0072B2")
legend("topright", bty = "n", lty = 2, lwd = 2,
       col = c("#D55E00", "#0072B2"),
       legend = c(paste("Media:", round(media, 2)),
                  paste("Mediana:", mediana)))
```



Distribución bimodal, con dos grupos separados por un hueco: 20 lotes entre 2,5 y 4,5 t/ha y 10 lotes entre 6 y 8,5 t/ha, y ningún lote entre 4,5 y 6 t/ha. La media (4,74) cae en el hueco y la mediana (3,95) queda en el grupo mayoritario. Los grupos coinciden con los cultivos.

Boxplot: rendimiento por cultivo

```
par(las = 1)
boxplot(rendimiento_t_ha ~ cultivo, data = datos, ylim = c(2, 9),
        col = NA, border = NA,
        main = "Rendimiento por cultivo",
        xlab = "Cultivo", ylab = "Rendimiento (t/ha)")
grid(nx = NA, ny = NULL, col = "gray85", lty = 1)
boxplot(rendimiento_t_ha ~ cultivo, data = datos, add = TRUE, outline = FALSE,
        col = adjustcolor(colores, alpha.f = 0.35), border = colores,
        boxwex = 0.5)
stripchart(rendimiento_t_ha ~ cultivo, data = datos, add = TRUE,
           vertical = TRUE, method = "jitter", jitter = 0.08,
           pch = 19, col = colores)
```



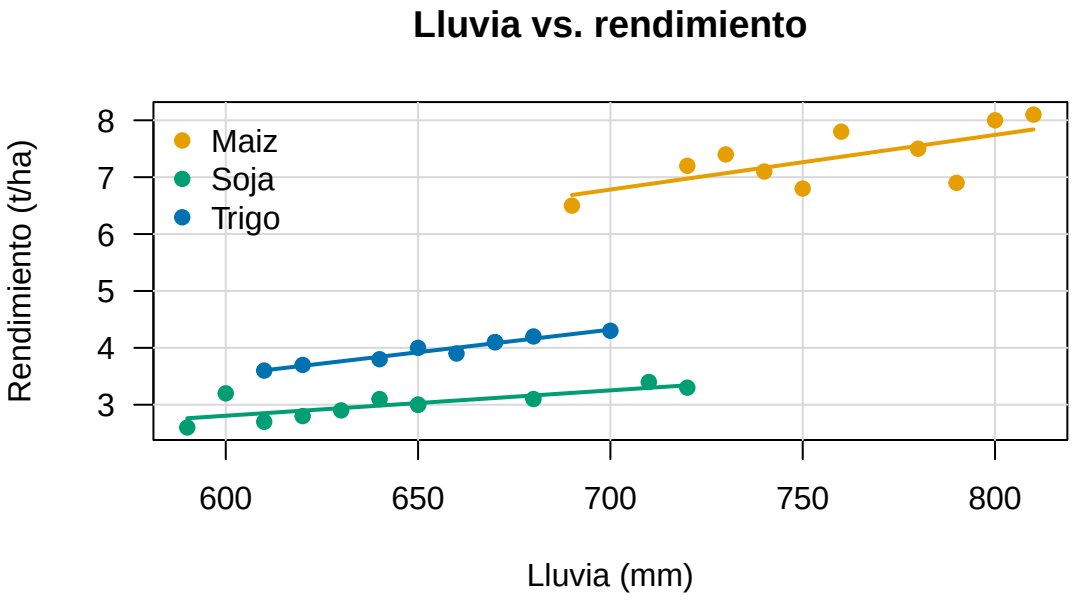
Las 3 cajas no se superponen. El maíz (6,5 a 8,1 t/ha), con una mediana de 7,3, tiene una caja más alta, o sea, más variación entre sus lotes. No se ven puntos atípicos, y los puntos sobre las cajas muestran que cada una resume entre 9 y 11 lotes.

La soja va de 2,6 a 3,4 t/ha (mediana 3,0) y el trigo de 3,6 a 4,3 t/ha (mediana 4,0). Los dos grupos del histograma son entonces el maíz, por un lado, y la soja y el trigo, por el otro. Producir más toneladas por hectárea no implica más ganancia: en la base no hay precios ni costos.

Dispersión: lluvia vs. rendimiento

```
par(las = 1)
plot(datos$lluvia_mm, r, type = "n",
     main = "Lluvia vs. rendimiento",
     xlab = "Lluvia (mm)", ylab = "Rendimiento (t/ha)")
grid(col = "gray85", lty = 1)
points(datos$lluvia_mm, r, pch = 19, col = colores[datos$cultivo])

for (cu in names(colores)) {
  lotes_cu <- datos[datos$cultivo == cu, ]
  modelo   <- lm(rendimiento_t_ha ~ lluvia_mm, data = lotes_cu)
  ord      <- order(lotes_cu$lluvia_mm)
  lines(lotes_cu$lluvia_mm[ord], fitted(modelo)[ord], col = colores[cu], lwd = 2)
}
legend("topleft", legend = names(colores), col = colores, pch = 19, bty = "n")
```

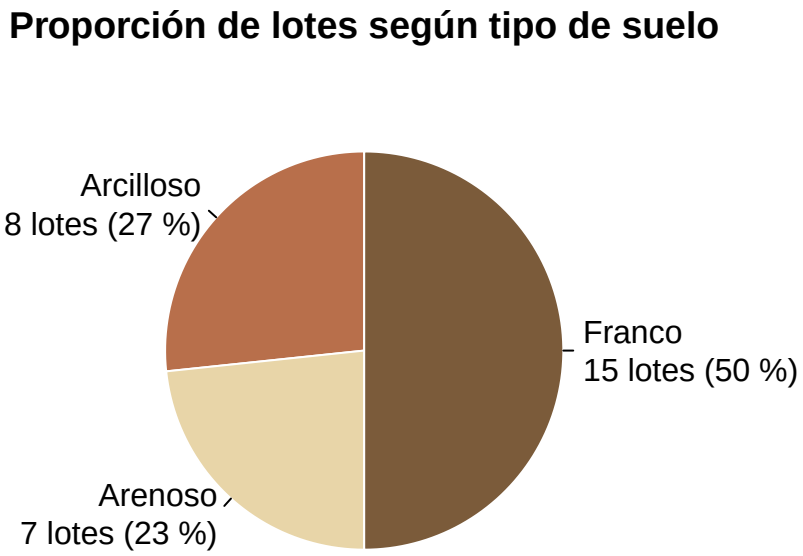


Dentro de cada cultivo, más lluvia se asocia a más rendimiento: cada 100 mm más acompañan aproximadamente +1,0 t/ha en maíz, +0,8 en trigo y +0,45 en soja. Con lluvias similares los cultivos rinden distinto: a 720 mm el maíz rinde 7,2 t/ha y la soja 3,3. La mayor parte de la diferencia entre lotes viene del cultivo y no de la lluvia, porque con la misma lluvia la brecha entre maíz y soja sigue siendo enorme.

Es una asociación: no prueba que la lluvia cause el mayor rendimiento, y cada recta se apoya en solo 9 a 11 lotes.

Torta: tipo de suelo

```
suelo <- table(datos$tipo_suelo)
pct   <- round(100 * as.vector(suelo) / sum(suelo))
etiquetas <- paste0(names(suelo), "\n", as.vector(suelo), " lotes (", pct, "%)")
colores_suelo <- c(Arcilloso = "#B86F4B", Arenoso = "#E8D5A8", Franco = "#7B5B3A")
par(mar = c(2, 2, 3, 6))
pie(suelo, labels = etiquetas, col = colores_suelo[names(suelo)],
    border = "white", init.angle = 90,
    main = "Proporción de lotes según tipo de suelo")
```



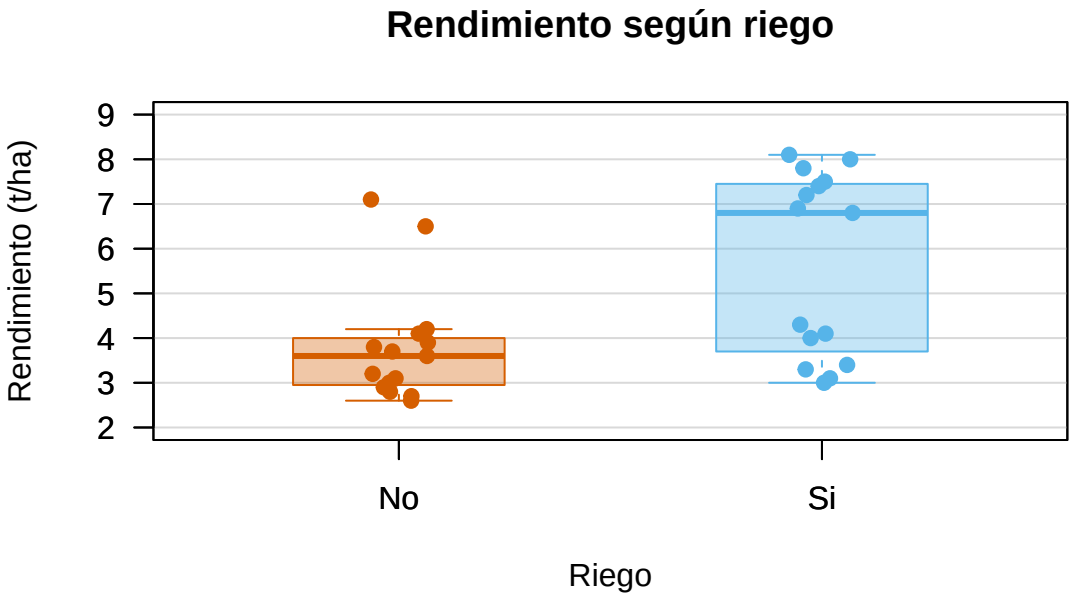
La mitad de los lotes tiene suelo franco, y los otros dos tipos se reparten casi parejo.

Parte 5: Pregunta de negocio, efecto del riego

16. Boxplot del rendimiento según riego

```
par(mar = c(5, 4, 4, 2) + 0.1, las = 1)
colores_riego <- c(No = "#D55E00", Si = "#56B4E9")

boxplot(rendimiento_t_ha ~ riego, data = datos, ylim = c(2, 9),
        col = NA,
        border = NA,
        main = "Rendimiento según riego",
        xlab = "Riego",
        ylab = "Rendimiento (t/ha)")
grid(nx = NA, ny = NULL, col = "gray85", lty = 1)
boxplot(rendimiento_t_ha ~ riego, data = datos, add = TRUE, outline = FALSE,
        col = adjustcolor(colores_riego, alpha.f = 0.35),
        border = colores_riego, boxwex = 0.5)
stripchart(rendimiento_t_ha ~ riego, data = datos, add = TRUE,
           vertical = TRUE, method = "jitter", jitter = 0.08,
           pch = 19, col = colores_riego)
```



Rendimiento medio

```
table(datos$riego)
```

```
##
## No Si
## 15 15
```

```
medias_riego <- tapply(r, datos$riego, mean)
```

17. Rendimiento medio con riego

```
cat("Rendimiento medio con riego:", round(medias_riego["Si"], 2), "t/ha\n")
```

```
## Rendimiento medio con riego: 5.66 t/ha
```

18. Rendimiento medio sin riego

```
cat("Rendimiento medio sin riego:", round(medias_riego["No"], 2), "t/ha\n")
```

```
## Rendimiento medio sin riego: 3.81 t/ha
```

19. ¿Cuál presenta mayor rendimiento promedio?

```
diferencia <- medias_riego["Si"] - medias_riego["No"]
cat("Diferencia (con riego - sin riego):", round(diferencia, 2), "t/ha\n")
```

```
## Diferencia (con riego - sin riego): 1.85 t/ha
```

```
cat("Aumento relativo:", round(100 * diferencia / medias_riego["No"]), "%\n")
```

```
## Aumento relativo: 48 %
```

```
mayor <- names(which.max(medias_riego))
cat("Mayor rendimiento promedio:",
    ifelse(mayor == "Si", "lotes con riego", "lotes sin riego"), "\n")
```

```
## Mayor rendimiento promedio: lotes con riego
```

20. Interpretación del efecto del riego

```
# ¿Está el riego repartido parejo entre cultivos?
table(datos$cultivo, datos$riego)
```

```
##
##         No Si
##   Maiz   2  8
##   Soja   7  4
##   Trigo  6  3
```

```
round(prop.table(table(datos$cultivo, datos$riego), margin = 1) * 100)
```

```
##
##         No Si
##   Maiz  20 80
##   Soja  64 36
##   Trigo 67 33
```

```
# Comparación dentro de cada cultivo (distinto objeto y distinto nombre
# que medias_riego: acá hay una media por cultivo y por grupo de riego)
aggregate(rendimiento_t_ha ~ cultivo + riego, data = datos, FUN = mean)
```

```
##   cultivo riego rendimiento_t_ha
## 1    Maiz    No         6.800000
## 2    Soja    No         2.900000
## 3   Trigo    No         3.883333
## 4    Maiz    Si         7.462500
## 5    Soja    Si         3.200000
## 6   Trigo    Si         4.133333
```

```r
medias_cr <- tapply(r, list(datos$cultivo, datos$riego), mean)
dif_cr    <- medias_cr[, "Si"] - medias_cr[, "No"]   # diferencia en cada cultivo
n_cult    <- as.vector(table(datos$cultivo))
dif_ajustada <- sum(dif_cr * n_cult) / sum(n_cult)   # promedio ponderado por lotes
cat("Diferencia global:", round(diferencia, 2), "t/ha\n")
```

```
## Diferencia global: 1.85 t/ha
```

```r
cat("Diferencia dentro de cada cultivo (promedio ponderado):",
    round(dif_ajustada, 2), "t/ha\n")
```

```
## Diferencia dentro de cada cultivo (promedio ponderado): 0.41 t/ha
```

```r
# Otras variables que también cambian con el riego
aggregate(cbind(lluvia_mm, fertilizante_kg_ha) ~ riego, data = datos, FUN = mean)
```

```
##   riego lluvia_mm fertilizante_kg_ha
## 1    No  643.3333            95.0000
## 2    Si  728.0000           122.6667
```

Los lotes con riego rinden en promedio 5,66 t/ha y los lotes sin riego 3,81 t/ha, una diferencia de 1,85 t/ha (alrededor de 48 % más). Esa diferencia está inflada por la composición de los grupos. El riego no está repartido parejo entre cultivos: 8 de 10 lotes de maíz (80 %) tienen riego, contra 4 de 11 de soja (36 %) y 3 de 9 de trigo (33 %). Como el maíz rinde bastante más que los otros cultivos, el grupo con riego tiene más maíz. Al comparar dentro de cada cultivo, los lotes con riego siguen rindiendo algo más, pero la diferencia es mucho menor: +0,66 t/ha en maíz, +0,30 en soja y +0,25 en trigo.

Conclusión general

La base tiene 30 lotes y 8 variables, sin datos faltantes. El rendimiento medio es 4,74 t/ha, pero ningún lote rinde cerca de este valor: hay dos grupos (soja y trigo entre 2,6 y 4,3 t/ha; maíz entre 6,5 y 8,1 t/ha), y eso explicaría la gran dispersión (IQR de 3,75 t/ha) sin valores atípicos. La lluvia acompaña al rendimiento dentro de cada cultivo, pero la mayor parte de la diferencia entre lotes viene del cultivo. Los lotes con riego rinden más (1,85 t/ha), pero esa brecha se reduce a unos 0,4 t/ha al comparar dentro de cada cultivo. Como el análisis es descriptivo y se basa en 30 lotes, los resultados describen esta base: no permiten generalizar ni establecer causas, y sin precios ni costos tampoco permiten decir qué cultivo o práctica conviene económicamente.

Principios básicos de la estadística aplicados en este TP

- **Población y muestra:** los 30 lotes son una muestra; no sabemos cómo se eligieron, por eso no generalizamos.
- **Tipos de variables:** categóricas (cultivo, suelo, riego), numéricas (rendimiento, lluvia, fertilizante, superficie) e identificador (lote).

- **Estadística descriptiva vs. inferencial:** este TP describe los datos; no hace inferencia sobre una población más grande.
- **Medidas resumen:** tendencia central (media, mediana, moda), dispersión (rango, IQR) y posición (cuartiles). Ninguna sola alcanza si la distribución tiene dos grupos.
- **Variabilidad y forma de la distribución:** el promedio solo no describe los datos; hay que mirar cómo se reparten (histograma, boxplot).
- **Visualización:** el gráfico se elige según el tipo de variable.
- **Correlación no implica causalidad,** y las variables confusoras (cultivo) pueden inflar una diferencia entre grupos.